

Resumen de Artículos y Convergencia con la Autocorrelación Espacial

Katia Daishy Ticona Casa

7 de octubre de 2025

1. Definición de Autocorrelación Espacial

La **Autocorrelación Espacial** es una medida estadística que cuantifica el grado de dependencia o similitud de un atributo geográfico entre ubicaciones adyacentes. Se utiliza para determinar si la distribución de un fenómeno es aleatoria o si presenta un **patrón de agrupamiento (clustering)**.

- **Autocorrelación Positiva:** Indica que los valores altos (o bajos) tienden a agruparse en el espacio.
- **Medición Clave:** El **Índice de Moran (I)** es el estadístico más común. Un valor de I cercano a +1 indica una fuerte correlación positiva. La fórmula general es:

$$I = \frac{N \sum_{i=1}^N \sum_{j=1}^N w_{ij} (x_i - \bar{x})(x_j - \bar{x})}{\left(\sum_{i=1}^N \sum_{j=1}^N w_{ij} \right) \sum_{i=1}^N (x_i - \bar{x})^2}$$

donde N es el número de unidades espaciales, x_i es el valor de la variable en la unidad i , \bar{x} es la media de la variable, y w_{ij} es la matriz de pesos espaciales.

2. Convergencia Metodológica Detallada

La convergencia principal es la elevación de la \mathcal{A} de una estadística descriptiva a un **precursor analítico** crítico para la modelización. Los tres artículos utilizan la \mathcal{A} para validar la necesidad de un enfoque espacializado.

Criterio	Artículo 1 (Vegetación)	Artículo 2 (Riesgo Costero)	Artículo 3 (Paperas)
Tipo de AE	Autocorrelación Espacial Bivariada (Bi-SA)	Moran Global (GMI)	Moran Global y Local (LISA)
Objetivo Analítico	Explorar la correlación espacial entre dos variables: NDVI vs. Factores Climáticos.	Evaluar la contigüidad y propagación del riesgo (EI) entre segmentos costeros adyacentes.	Identificar hotspots y coldspots significativos de la enfermedad.
Resultado Clave	Fuerte correlación espacial positiva ($I_{Bi} \approx 0,88$) entre NDVI y Precipitación.	Fuerte agrupamiento del riesgo ($I \approx 0,7$), indicando continuidad espacial del riesgo.	Agrupamiento Alto-Alto (AA) en el oeste y Bajo-Bajo (BB) en el este.

3. Análisis Preciso por Artículo

3.1. Art 1 - Aplicación (Ecosistemas de Estepa Desertificada)

Precisión: El uso de la **Bi-SA** es fundamental, ya que no solo confirmó el agrupamiento del **NDVI**, sino que aisló la dependencia espacial del **NDVI con respecto a la precipitación** con un valor de $I_{Bi} = 0,88$ ($P < 0,01$). Esto demuestra que el impacto del clima no es uniforme, sino que las áreas de alto NDVI se correlacionan espacialmente con áreas de alta precipitación, formando *clusters* geográficos de productividad.

3.2. Art 2 - Aplicación (Exposición Costera al Aumento del Nivel del Mar)

Precisión: El alto valor del **Moran Global** ($I \approx 0,7$) para el Índice de Exposición (EI) es la prueba estadística de que la **gestión de riesgos** debe ser integrada. Un valor tan alto descarta la variación aleatoria y confirma que la gestión en un segmento costero afectará a los segmentos adyacentes debido a la continuidad espacial de procesos como la erosión. El riesgo es, por lo tanto, una variable que se propaga geográficamente.

3.3. Art 3 - Aplicación (Incidencia de Paperas/Salud Pública)

Precisión: La aplicación del **LISA (Análisis de Agrupamiento Espacial Local)** fue clave para la toma de decisiones. Permitió ir más allá del Moran Global para identificar geográficamente los focos específicos (clusters **Alto-Alto**) en las regiones occidentales. Esta identificación de la **Heterogeneidad Estratificada Espacial** justificó la aplicación del **Geodetector** para evaluar cómo los factores socioeconómicos y ambientales varían su influencia en función de la ubicación geográfica (oeste vs. este).

4. Bloque de Código en R: Implementación de la Autocorrelación Espacial

El siguiente código en el lenguaje R implementa el proceso central de **Moran Global** y **Moran Local (LISA)**, similar al enfoque utilizado en los Artículos 2 y 3. El código simula un conjunto de datos espaciales y calcula los índices.

```
# =====
# ANÁLISIS DE AUTOCORRELACIÓN ESPACIAL EN R
# Ejemplo con provincias del Perú (usando GADM)
# =====

library(sf)
library(spdep)
library(tmap)
library(rnaturalearth)
library(rnaturalearthhires)

# 1 Cargar datos geoespaciales del Perú
peru_sf <- ne_states(country = "Peru", returnclass = "sf")

# 2 Crear variable de interés (simulada)
set.seed(123)
peru_sf$variable_interes <- runif(nrow(peru_sf), 0, 100)

# 3 Matriz de pesos espaciales (contigüidad tipo reina)
vecindarios <- poly2nb(peru_sf)
lista_pesos <- nb2listw(vecindarios, style = "W")

# 4 Índice de Moran Global
moran_global <- moran.test(peru_sf$variable_interes, lista_pesos)
print(moran_global)

# 5 Índice LISA
moran_local <- localmoran(peru_sf$variable_interes, lista_pesos)
peru_sf$moran_i <- moran_local[, "Ii"]
peru_sf$moran_p <- moran_local[, "Pr(z != E(Ii))"]

peru_sf$lisa_cluster <- "No significativo"
peru_sf$lisa_cluster[peru_sf$moran_p < 0.05 & peru_sf$moran_i > 0] <- "Alto-Alto"
peru_sf$lisa_cluster[peru_sf$moran_p < 0.05 & peru_sf$moran_i < 0] <- "Bajo-Bajo"
```

```
# 6 Visualizar mapa
tmap_mode("view")
tm_shape(peru_sf) +
  tm_polygons("lisa_cluster",
    palette = c("red", "blue", "white"),
    title = "Clusters LISA") +
  tm_layout(legend.outside = TRUE)
```